

Introducció a la intel·ligència artificial - 3

Aina Palacios

Aina Palacios

- Enginyera de Telecomunicacions especialitzada en Audiovisuals
- Màster en Tecnologies Avançades especialitzada en deep learning en Multimèdia!
- Experiència en programació web i machine learning.
- Mentora a IT Academy de **DataScience**



<https://www.linkedin.com/in/ainapc/>



ainaPali#2617

Deep Learning

Machine Learning

Algoritmes que analitzen les dades, aprenen d'elles i fan decisions respecte al que han après

2

Deep Learning


Nova evolució del Machine Learning basat en la forma que aprenen els humans. Basat en Neural Networks

1

Intel·ligència artificial

Tot allò que engloba comportaments intel·ligents.


3



Perquè volem utilitzar deep learning?


- Està basat en Neural Network (Xarxes Neuronals), per tant és el més proper al comportament humà que tenim!!
- Quan la data és desestructurada o és complexa, deep learning és la solució!
- Molt utilitzat sobretot en image recognition, speech, and computer vision applications.
- Són molt molt ràpides a l'hora de funcionar!
- Podem fer servir xarxes ja entrenades

Desavantatges: Necessita molta molta dada i complex i llarg entrenament




Machine Learning vs Deep Learning


Machine Learning




Deep Learning



Neural Networks: THE PERCEPTRON



NEURON





PERCEPTRON

The hidden layer!

Amb una neurona, no podem predir res. Però què passa si ajuntem un munt de Perceptrons?

La idea de les **Neural Networks** és crear una estructura amb una layer d'entrada, ona o moltes hidden layers i una output layer.

Així, les entrades de els nostres perceptrons seran primerament les input layers i seguidament les hidden layers.



MATHS!


Durant l'entrenament, les xarxes modifiquen els seus pesos per intentar reduir l'error al màxim! És el que en diem Backpropagation.

Més info:

<https://hmkcode.com/ai/backpropagation-step-by-step/>




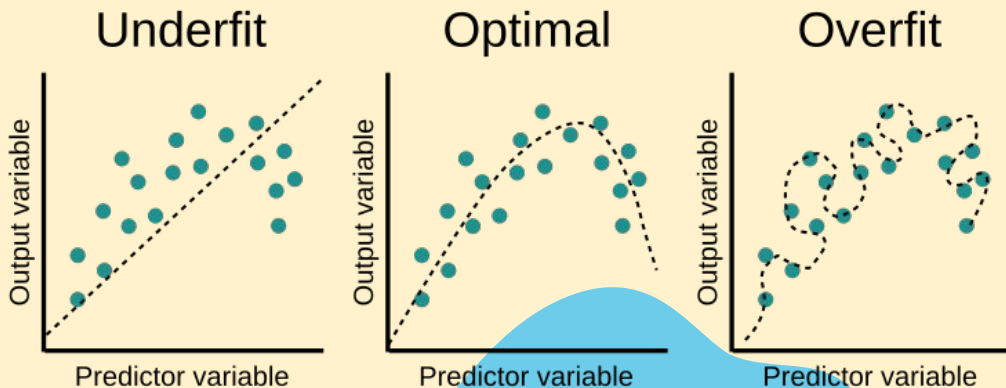
Training in
progress...



Train and Test!

Utilitzarem, si són dades molt senzilles, poques hidden layers, per evitar overfitting (que s'adapti massa al train).

Hi ha molts mètodes per saber quan parar l'entrenament: Si l'error és molt petit, si l'error ja no disminueix en el temps, si detectem overfitting, nombre d'iteracions..



Deep learning process

Training data



Feature vector

Label

(135, 57, 3, 98, ...) (Bread)

(256, 67, 15, 46, ...) (Corgi)

(1, 354, 2, 479, ...) (Bread)


(576, 32, 6, 441, ...) (Corgi)

Testing data



(39, 198, 95, 81, ...) (?)

Deep learning NN layers



Inference




Output

(Corgi)



784

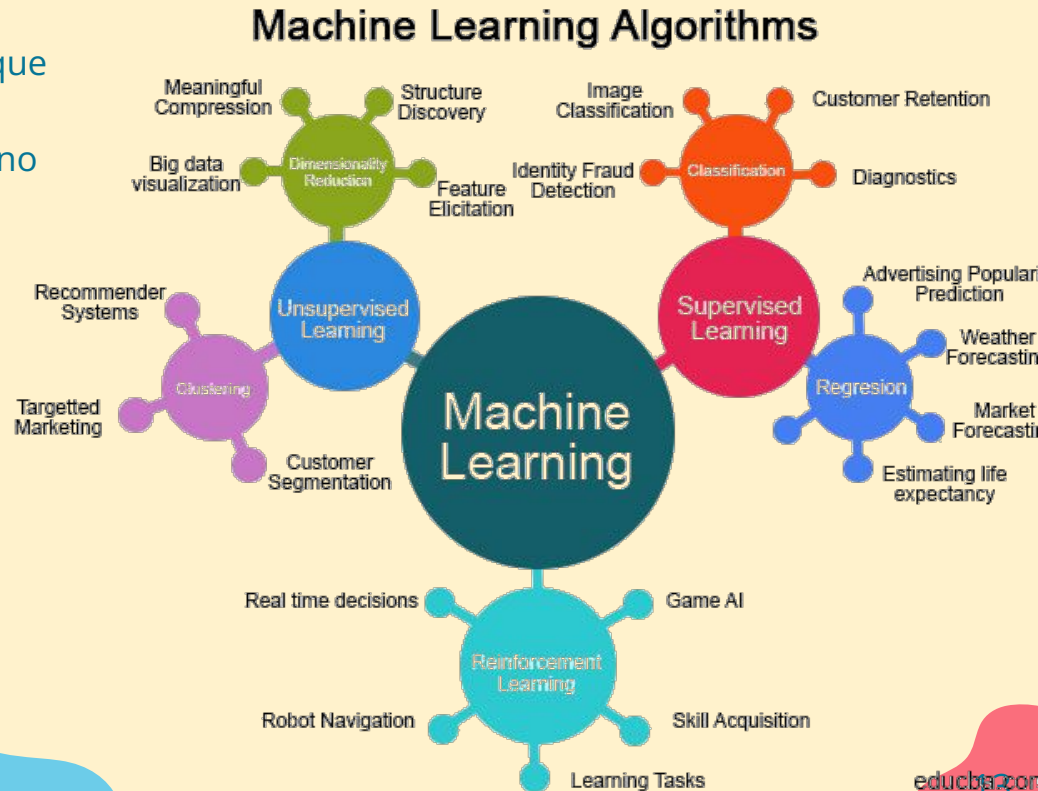


Deep Learning


Una xarxa neuronal pot extreure informació que altres algoritmes no poden, sobretot quan les dades no segueixen una estructura normal o no tenim etiquetes.

Aquestes, poden fer de tot!!! Podem fer regressió (extreure un resultat numèric), classificació, unsupervised, reinforcement learning, computer vision...

Quan una xarxa neuronal conté més d'una hidden layer, en diem deep learning, d'aquí prové el nom.




1980S-ERA NEURAL NETWORK



Links carry signals from one node to another, boosting or damping them according to each link's 'weight'.

DEEP LEARNING NEURAL NETWORK




Aplicar Deep Learning

A vegades, et pots trobar dades que no s'adapten bé als models escollits, ja que tenen una estructura estranya. Sempre pots provar d'utilitzar les Xarxes Neuronals!

Crear una xarxa neuronal des de 0 és bastant complex, però per sort la llibreria sklearn ens permet utilitzar-les!
https://scikit-learn.org/stable/modules/neural_networks_supervised.html#

Exemple:
<https://www.kaggle.com/code/ahmethamzaemr/a/mlpclassifier-example/notebook>



La complexitat de les Xarxes Neuronals

Les Xarxes Neuronals poden ser útils per moltes coses, però com sempre, tot depèn de les dades. Moltes vegades alguns algorismes matemàtics podran tenir millor prediccions que una NN. Algunes, la combinació de models pot ser la solució.

A més, aquestes conenten un munt de paràmetres que necessiten molt estudi per interpretar bé.

Pensa que qualsevol modificació, qualsevol estat d'inici, pot alterar el resultat final enormement.

L'estudi d'aquest model porta anys estudiant-se, i moltes vegades, ni els professionals entenem perquè pot variar tant les dades al posar noves hidden layers.

Molta gent es dedica únicament a descobrir nous tipus de layers i posicionar-les de manera que alterin el resultat final.

Lliberies per crear Xarxes

Pytorch

PyTorch is an open source machine learning library for Python, based on Torch. It is used for applications such as natural language processing and was developed by Facebook's AI research group.

TensorFlow

TensorFlow is an open-source software library for dataflow programming across a range of tasks. It is a symbolic math library that is used for machine learning applications like neural networks.

Keras

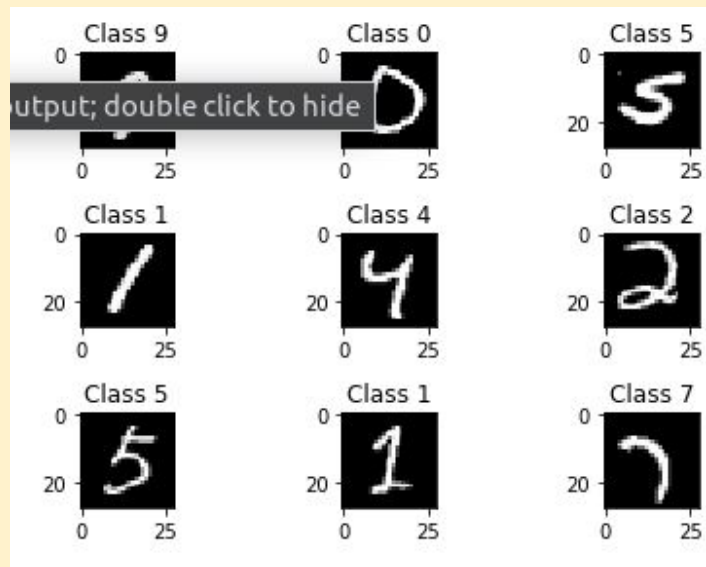
Keras is an open source neural network library written in Python. It is capable of running on top of TensorFlow. It is designed to enable fast experimentation with deep neural networks.

Keras API i MNIST

```
(X_train, y_train), (X_test, y_test) = mnist.load_data()

print("X_train shape", X_train.shape)
print("y_train shape", y_train.shape)
print("X_test shape", X_test.shape)
print("y_test shape", y_test.shape)
```

```
X_train shape (60000, 28, 28)
y_train shape (60000,)
X_test shape (10000, 28, 28)
y_test shape (10000,)
```



Modificant la input layer

Ens interessa crear un únic vector per l'entrada d'aquesta xarxa, per tant haurem de passar d'una imatge de dos dimensions a una. A més normalitzarem les imatges per tenir-les al rang [0,1]

```
X_train = X_train.reshape(60000, 784) # reshape 60,000 28 x 28 matrices into 60,000 784-length vectors.
X_test = X_test.reshape(10000, 784)   # reshape 10,000 28 x 28 matrices into 10,000 784-length vectors.

X_train = X_train.astype('float32')    # change integers to 32-bit floating point numbers
X_test = X_test.astype('float32')

X_train /= 255                          # normalize each value for each pixel for the entire vector for each input
X_test /= 255

print("Training matrix shape", X_train.shape)
print("Testing matrix shape", X_test.shape)
```

Training matrix shape (60000, 784)
Testing matrix shape (10000, 784)

Modificant el target

El que volem és aplicar one-hot al target per tenir per cada classe un node, que ens indicarà entre el valor 0 i l'1 la probabilitat d'aquella classe:

[0, 0.94, 0, 0, 0, 0, 0.06, 0, 0]

El més probable és que sigui 1

```
nb_classes = 10 # number of unique digits



Y_train = np_utils.to_categorical(y_train, nb_classes)
Y_test = np_utils.to_categorical(y_test, nb_classes)
```

```
model = Sequential()
```

```
model.add(Dense(512, input_shape=(784,)))  #(784,) is not a typo -- that represents a 784 length vector!  
model.add(Activation('relu'))  
model.add(Dropout(0.2))
```

```
model.add(Dense(512))  
model.add(Activation('relu'))  
model.add(Dropout(0.2))
```

```
model.add(Dense(10))  
model.add(Activation('softmax'))
```



```
model.compile(loss='categorical_crossentropy', optimizer='adam', metrics=['accuracy'])
```


```
from sklearn.model_selection import train_test_split
```

```
X_train, X_val, Y_train, Y_val = train_test_split(X_train, Y_train, test_size=0.15, random_state=42)
```


```
results = model.fit(X_train, Y_train,  
                    batch_size=64, epochs=10,  
                    verbose=1, validation_data=(X_val, Y_val))
```

```
Epoch 1/10  
354/354 [=====] - 3s 7ms/step - loss: 0.0307 - accuracy: 0.9947 - val_loss: 0.0109 - val_  
accuracy: 0.9979  
Epoch 2/10  
354/354 [=====] - 3s 8ms/step - loss: 0.0100 - accuracy: 0.9979 - val_loss: 0.0065 - val_  
accuracy: 0.9989  
Epoch 3/10  
354/354 [=====] - 3s 7ms/step - loss: 0.0054 - accuracy: 0.9986 - val_loss: 0.0055 - val_  
accuracy: 0.9985  
Epoch 4/10  
354/354 [=====] - 3s 7ms/step - loss: 0.0063 - accuracy: 0.9988 - val_loss: 0.0056 - val_  
accuracy: 0.9985  
Epoch 5/10  
354/354 [=====] - 3s 8ms/step - loss: 0.0042 - accuracy: 0.9986 - val_loss: 0.0037 - val_  
accuracy: 0.9985  
Epoch 6/10
```

Training & Validation 'loss' vs Epochs



Confusion matrix



References

- MNIST en keras Google Collab [[link](#)]
 - TensorFlow MNIST [[link](#)]
 - MNIST — Digits Classification with Keras [[link](#)]
 - Keras API [[link](#)]
 - Overffiting en TensorFlow [[link](#)]
-
- NLP en Keras [[link](#)]

Fins on pot arribar el Deep Learning?



Classification




CAT

Classification + Localization



CAT

Object Detection



CAT, DOG, DUCK

Instance Segmentation




CAT, DOG, DUCK

Single object

Multiple objects

GAN's Generative Adversarial Networks



Feature Visualization



Ja hem acabat la part 2!

Gràcies a tots!

